

HƯỚNG DẪN THỰC HIỆN - TASK 2

Mục tiêu: Xử lý Dữ liệu, Triển khai Baseline & Phát triển Phương pháp Đề xuất (Proposed Method Iterations)

PHẦN 1: CÁC NỘI DUNG CẦN HOÀN THÀNH

1. Giai đoạn 1: Chuẩn bị & Xử lý Dữ liệu (Dataset Pipeline): Xây dựng nền tảng dữ liệu sạch và chuẩn hóa cho dữ liệu.

- 1.1. Thống kê nguồn dữ liệu:

- Thống kê chi tiết lượng dữ liệu thu thập Online (public datasets, web scraping, API) và dữ liệu thu thập Offline (tự chụp, tự thu âm, khảo sát thực địa).
- Lập bảng tổng hợp các trường dữ liệu, định dạng file, kích thước dung lượng.

- 1.2. Phương pháp Làm sạch & Gán nhãn (Data Cleaning & Labeling):

- Mô tả rõ quy trình làm sạch: Loại bỏ trùng lặp, nhiễu (noise), xử lý giá trị thiếu (missing values), chuẩn hóa định dạng (resolution, sample rate, text lowercasing...).
- Công cụ và quy trình gán nhãn (Label Studio, CVAT, Roboflow...): Tiêu chí gán nhãn, đo lường độ đồng nhất giữa người gán nhãn (Inter annotator agreement Fleiss' Kappa/Cohen's Kappa nếu có sử dụng).

- 1.3. Thống kê mô tả & Phân tích mất cân bằng (Data Imbalance):

- Thống kê số lượng mẫu theo từng lớp (class distribution), phân bố tập Train/Val/Test (tỷ lệ thường dùng 70/15/15 hoặc 80/10/10).
- Trực quan hóa bằng biểu đồ, minh họa rõ mức độ mất cân bằng dữ liệu gốc.
- Các bạn phải: Đưa ra nhận xét định lượng** (ví dụ: Lớp A chiếm 80%, Lớp B chỉ chiếm 5%). **Không trình bày định tính (ô tả chung chung)**

- 1.4. Đề xuất & Báo cáo kết quả xử lý mất cân bằng:

- Đề xuất giải pháp áp dụng: Class Weighting, Data Augmentation, Resampling (Oversampling/Undersampling, SMOTE), Focal Loss...
- Báo cáo và so sánh trực quan hóa distribution **trước và sau** khi xử lý.

- 1.5. Đối với Đề tài RAG (Retrieval-Augmented Generation)

Các nhóm thực hiện đề tài RAG/LLM, các bạn trình bày quy trình Data Engineering chi tiết:

1. Phương pháp Chunking:

- Trình bày chiến lược cắt đoạn: Fixed-size, Sentence-level, Paragraph-level, Semantic Chunking, hoặc Recursive Character Chunking.
- Thông số cấu hình: Chunk size, Chunk overlap (lý do chọn thông số).

2. Xử lý Embedding & Kiểm soát Token:

- Chọn Embedding Model (VD: bge-m3, text-embedding-3-small...); giải thích lý do lựa chọn.
- Tính toán tổng số lượng Token, chi phí ước tính (nếu dùng API) hoặc thời gian/tài nguyên tính toán (nếu dùng local model).

3. Cấu trúc lưu trữ & Vector Database:

- Lựa chọn Vector DB (ChromaDB, Qdrant,...).
- Mô tả Schema lưu trữ: Vector, Metadata (Nguồn, trang, tác giả, timestamp...).
- Đảm bảo kiến trúc chỉ cho phép LLM truy xuất thông tin từ Vector DB (Grounding) để chống hiện tượng Ảo giác (Hallucination).
- **Output:** Xuất và kiểm tra định dạng File dữ liệu sau xử lý (JSONL, Parquet...).

2. Giai đoạn 2: Tái dựng 2 Mô hình Baseline trên Dataset.

• 2.1. Triển khai dựng Baseline

- Triển khai 2 mô hình Baseline đã chọn ở Task 1 trên tập Dataset của nhóm.
- Đảm bảo môi trường thực nghiệm đồng nhất (Hardware, Seed, Learning rate, Optimizer, Epochs).

• 2.2. So sánh kết quả công bố vs Kết quả thực nghiệm:

- Lập bảng so sánh các chỉ số đánh giá (Accuracy, Precision, Recall, F1-score, mAP, BLEU...) giữa **Bài báo công bố gốc (Paper)** và **Thực nghiệm của nhóm**

• 2.3. Báo cáo & Đánh giá lý do lệch kết quả (Gap Analysis):

- Trình bày rõ: Kết quả thực nghiệm có phù hợp/tương đồng với công bố hay không?
- Nếu có chênh lệch lớn, phân tích nguyên nhân: Do sự khác biệt về Dataset (domain gap), siêu tham số (hyperparameters), hay kỹ thuật tiền xử lý?

3. Giai đoạn 3: Thực nghiệm & Phát triển Proposed Method (V1, V2, ... Vn): Đánh giá cải tiến liên tục và tính khả thi của sản phẩm.

- **3.1. Triển khai Proposed Method V1:**
 - Cài đặt mô hình cải tiến theo đề xuất Task 1.
 - Phân tích: V1 có tạo ra "tín hiệu cải thiện" (positive improvement signal) so với 2 Baseline hay không?
 - Trực quan hóa kết quả V1: Confusion Matrix, Loss/Metric curves, Grad-CAM/Attention maps (nếu có).
- **3.2. Phân tích lỗi (Failure Cases Analysis) của V1:**
 - Trích xuất và hiển thị trực quan các mẫu dự đoán sai/kém chất lượng của V1.
 - Phân tích nguyên nhân chính (core Analysis): Nhiều dữ liệu, thiếu đặc trưng (feature bottleneck)...
- **3.3. Đề xuất & Thực nghiệm các phiên bản tiếp theo (V2, V3...):**
 - Dựa trên việc phân tích lỗi V1, đưa ra phương án chỉnh sửa kiến trúc/hàm loss/kỹ thuật huấn luyện cho V2, V3...
 - Lập bảng theo dõi tiến trình qua từng phiên bản.
- **3.4. Kết luận tính khả thi xây dựng sản phẩm cuối:**
 - Đánh giá tổng thể: Độ chính xác, tốc độ suy luận (Latency/FPS), kích thước mô hình (Model size).
 - Đưa ra kết luận rõ ràng: Có đủ điều kiện khả thi để đóng gói thành ứng dụng/sản phẩm thực tế ở Task 3 hay không?

3.5. Đề tài RAG

Đối với đề tài RAG, sản phẩm không chỉ dừng ở File Notebook/Script huấn luyện mà phải thể hiện năng lực MLOps/DevOps:

1. Kiến trúc Microservices:

- Tách biệt các Service: Data Ingestion Service, Retrieval Service (Vector DB), LLM Generation Service, API Gateway / Frontend.
- Đóng gói từng dịch vụ bằng **Docker** (Dockerfile, docker-compose.yml).

2. Quy trình CI/CD:

- Xây dựng Pipeline tự động (dùng GitHub Actions / GitLab CI): Linting, Unit Test cho Data pipeline, Build Docker Image, Deploy tự động lên môi trường Staging/Server.

PHẦN 2: SLIDE BÁO CÁO TASK 2

Nhóm cần chuẩn bị bộ Slide báo cáo (khoảng 18 - 25 slides) trình bày báo cáo lần 2:

Slide 1: Slide Tiêu đề

- Ten đề tài - Mã nhóm - Tên sinh viên & GVHD.
- Tiêu đề phụ: *Báo cáo Tiến độ Task 2: Xử lý Dữ liệu, Thực nghiệm Baseline & Mô hình Đề xuất.*

Slide 2: Tổng quan Nội dung (Agenda)

- I. Xử lý & Phân tích Dữ liệu (Dataset Pipeline)
- II. Kết quả Thực nghiệm 2 Mô hình Baseline
- III. Phát triển & Đánh giá Mô hình Đề xuất (Proposed Method V1 -> Vn)
- IV. Phân tích Lỗi & Đánh giá Tính Khả thi Sản phẩm

CHƯƠNG I: XỬ LÝ & PHÂN TÍCH DỮ LIỆU

- **Slide 3: Thu thập & Tổng quan Dữ liệu gốc**
 - Bảng thống kê nguồn dữ liệu: Online (URL/Tên dataset public) và Offline (Số lượng mẫu, định dạng).
 - Ví dụ trực quan một số mẫu dữ liệu tiêu biểu.
- **Slide 4: Phương pháp Làm sạch & Gán nhãn**
 - Quy trình tiền xử lý dữ liệu (Flowchart làm sạch).
 - Mô tả công cụ và chuẩn gán nhãn đã sử dụng.
- **Slide 5: Thống kê Mô tả & Phân tích Mất cân bằng**
 - Bảng chia tập dữ liệu: Train / Validation / Test.
 - **Biểu đồ (Chart):** Phân bố các lớp dữ liệu trước xử lý -> Nhận xét về độ mất cân bằng.
- **Slide 6: Phương pháp & Kết quả Xử lý Mất cân bằng**
 - Kỹ thuật áp dụng (Augmentation, Class Weight, SMOTE...).
 - **Biểu đồ so sánh:** Phân bố dữ liệu Trước vs Sau khi xử lý mất cân bằng.

CHƯƠNG II: THỰC NGHIỆM MÔ HÌNH BASELINE

- **Slide 7: Cấu hình Môi trường Thực nghiệm**

- Hardware (GPU/CPU), Framework (PyTorch/TensorFlow), Các siêu tham số cố định (Epochs, Batch size, LR...).
- **Slide 8: Triển khai & Kết quả 2 Mô hình Baseline**
 - Bảng so sánh kết quả:
 - Baseline 1 (Paper vs Group's Execution)
 - Baseline 2 (Paper vs Group's Execution)
- **Slide 9: Báo cáo Đánh giá Chênh lệch (Gap Analysis)**
 - Nhận xét: Kết quả thực nghiệm có phản ánh đúng báo cáo gốc không?
 - Giải thích chi tiết nguyên nhân sự chênh lệch (nếu có).

CHƯƠNG III: PHÁT TRIỂN & CẢI TIẾN PROPOSED METHOD

- **Slide 10: Tổng quan Kiến trúc Proposed Method V1**
 - Nhắc lại điểm cải tiến chính so với Baseline (Sơ đồ khối kiến trúc V1).
- **Slide 11: Kết quả Thực nghiệm V1 & Tín hiệu Cải thiện**
 - Bảng so sánh chỉ số: **Baseline 1 vs Baseline 2 vs Proposed Method V1**.
 - Đánh giá: V1 đã tạo ra tín hiệu cải thiện ở chỉ số nào?
- **Slide 12: Phân tích Lỗi & Failure Cases (V1)**
 - Trực quan hóa các trường hợp suy luận sai tiêu biểu của V1 (Confusion Matrix, hình ảnh/văn bản dự đoán sai).
 - Phân tích lý do tại sao mô hình gặp lỗi ở các trường hợp này.
- **Slide 13: Đề xuất Cải tiến V2 (và các phiên bản tiếp theo)**
 - Giải pháp khắc phục lỗi của V1 -> Mô tả điểm mới trong V2 (Loss function mới, thêm module chú ý, tuning hyperparameter...).
- **Slide 14: Bảng Tổng hợp Kết quả Thực nghiệm (Ablation Study)**
 - Bảng so sánh xuyên suốt các phiên bản: **Baseline 1 | Baseline 2 | Proposed V1 | Proposed V2 | Proposed V-Final**.
 - Biểu đồ thể hiện sự gia tăng hiệu năng qua từng đợt thử nghiệm.

CHƯƠNG IV: KẾT LUẬN & ĐÁNH GIÁ TÍNH KHẢ THI SẢN PHẨM

- **Slide 15: Trực quan hóa Kết quả Đầu ra (Visual Results)**
 - Demo một số kết quả đầu ra tiêu biểu của mô hình tốt nhất (Visual Output / Predictions).
- **Slide 16: Đánh giá Tính Khả thi Xây dựng Sản phẩm**

- Phân tích các tiêu chí kỹ thuật: Accuracy, Tốc độ xử lý (Inference Time/FPS), Dung lượng mô hình (Model Size).
- Môi trường triển khai dự kiến ở Task 3 (Web/Mobile/Edge Device).
- Kết luận: **CÓ KHẢ THI** để phát triển thành sản phẩm hoàn chỉnh hay không.

- **Slide 17: Kế hoạch Thực hiện Task 3**

- Phân công công việc đóng gói mô hình (Deployment), xây dựng UI/UX, tích hợp API và viết Báo cáo Tốt nghiệp.

- **Slide 18: Cảm ơn và Q&A**